




פרויקט גמר


עיבוד שפה טבעית 99101 (NLP)

חיזוי מדד האיום (Bounty) בעולם One Piece

נדב פיירמן שטרן

מרצה: ד"ר איגור קליינר

רקע על העולם של One Piece



- One Piece - סדרת מאנגה ואנימה מאת אייצ'ירו אודה, מהפופולריות בעולם, שרצה מאז 1997
- עולם ימי כמעט כולו: יבשת ה-Red Line וה Grand Line חוצות אותו ומחלקות אותו לארבעה ימים - North Blue, East Blue, West Blue, South Blue
- ה Grand Line הוא הים המסוכן שבו שטים הפיראטים החזקים; חלקו השני, ה New World, הוא מחוז הכוח העליון
- הממשלה העולמית והמרינס אוכפים סדר; על כל דמות מאיימת מוכרז Bounty - פרס כספי "על ראשה"

הסבר על ה Bounty



- Bounty הוא פרס כספי (במטבע ברי - Berry \$, המטבע הרשמי בעולם One Piece) שהממשלה העולמית מכריזה על כל דמות שנחשבת מאיימת - ככל שהיא מסוכנת ומשפיעה יותר, כך הפרס גבוה יותר
- ה Bounty ידוע רק עבור חלק מהדמויות הרלוונטיות
- ה Bounty הוא מדד איום כמותי ורשמי בתוך עולם הסיפור - ולכן, משתנה מטרה טבעי לחיזוי מטקסט ומרשת הקשרים
- טווח הערכים עצום - מעשרות בודדות ועד כ-5.5 מיליארד (8 סדרי גודל)
- כ 30% מערכי ה Bounty הידועים הינם בעלי משמעות הפוכה (יורחב בהמשך)



גורמי הכוח בעולם

מאזן הכוח בעולם נחלק בין מספר גורמים - זה Bounty הוא הכלי שבו הממשלה מתרגמת את האיום שכל דמות מציבה לערך מספרי

צבא המהפכה

Revolutionary Army

ארגון שמטרתו הפלת הממשלה העולמית - האיום הישיר ביותר עליה. מנהיגו דרגון הוא המבוקש בעולם, למרות שאינו פיראט כלל

המרינס

Marines

הזרוע הצבאית של הממשלה שאוכפת את החוק ורודפת פיראטים. דרגת ה Bounty קובעת איזה כוח יוקצה לתפיסת דמות

הממשלה העולמית

World Government

הגוף השלטוני שמאחד מאות מדינות ומגדיר מיהו "פושע". היא זו שקובעת ומכריזה על ה Bounty של כל דמות מאיימת

השיצ'יבוקאי — שבעת אדוני הים

Shichibukai (Seven Warlords of the Sea)

שבעת הפיראטים החזקים שקיבלו חנינה בתמורה לשיתוף פעולה עם הממשלה. מקרה קצה מעניין: ה Bounty שלהם "מוקפא" כל עוד הם בעלי ברית

היונקו (הקיסרים)

Yonko

ארבעת הפיראטים החזקים בעולם, ששולטים בשטחים עצומים בים החדש. נושאים את ה Bounty הגבוה ביותר - מיליארדים

הפיראטים

Pirates

עמוד השדרה של הדאטה: כל שודד-ים שנחשב מאיים מקבל Bounty שגדל עם מעלליו. רוב הדמויות המתויגות בפרויקט הן פיראטים



שאלת המחקר

האם ניתן לחזות את ה Bounty של דמות מתוך התיאור הטקסטואלי שלה בוויקי ומתוך מיקומה ברשת הקשרים - ואיזה מקור מידע תורם יותר לדיוק החיזוי?

3

משולב

טקסט + רשת + מאפיינים מובנים (Haki, פרי שטן, האות D...)

2

רשת בלבד

6 מדדי מרכזיות מגרף הקשרים בין הדמויות

1

טקסט בלבד

TF-IDF + SVD, ציון "איום"



למה זו בעיה מאתגרת?

- אין קורלציה פשוטה: דמות יכולה להופיע הרבה בוויקי אך לשאת Bounty נמוך, ולהפך - אורך הטקסט לבדו אינו מנבא טוב
- פער בין מרכזיות לעוצמה: דמות עשויה לשבת במרכז הרשת (הרבה קשרים) אך להיות חלשה אישית, למשל טוני טוני צ'ופר, חבר צוות מפורסם עם Bounty נמוך במיוחד
- טווח ערכים קיצוני: 8 סדרי גודל בין ערכי ה-Bounty של הדמות הנמוכה לגבוהה
- מיעוט תוויות: דאטה קטן, שבו כל דוגמה רועשת משפיעה
- אתגר ייחודי: כ-30% מערכי ה-Bounty הגולמיים אינם פרס מבוקש אמיתי אלא דירוג-כוח (61 דירוגי מרינס, 5 של Cross Guild על אדמירלים) - פורמט זה בוויקי, משמעות הפוכה
- טקסט לא מובנה: תיאורי הוויקי נכתבו לקוראים אנושיים ולא כמאפיינים למודל - נדרש לחלץ מהם אות מנבא (ולסנן דליפות של ה-Bounty עצמו מהטקסט)



ה Pipeline

מסלול העבודה מקצה לקצה — מדף ויקי גולמי ועד לחיזוי Bounty וניתוח שגיאות



כל שלב במחברת מלווה בבדיקת-שפיות (sanity check) על הנתונים - לדוגמה כיסוי דגלי שיוכים, ואימות שגארפ מסומן כמרינס וקאידו כיונקו



איסוף הנתונים



1,734

דפי ויקי גולמיים שנאספו



סינון לא-דמויות ולא-קבוצי

1,542

דמויות סופיות



218

דמויות עם Bounty ידוע (משתנה המטרה)

+1,324 הדמויות ללא Bounty אינן נזרקות - הן בונות את גרף הקשרים המלא

- מקור: One Piece Fandom Wiki - איסוף עצמאי ואוטומטי דרך ה API הציבורי, ללא Kaggle וללא מאגר מוכן
- רישיון: CC BY-SA 3.0, שימוש אקדמי בייחוס; כל הדמויות בדיוניות - אין מידע אישי מזהה
- עבור כל דמות חילצתי:
 - שם
 - מספר קטלוגי
 - URL
 - טקסט




התפלגות ה Bounty




- הערכים הגולמיים עם פיזור רחב מאוד - נעים מעשרות בודדות ועד כ 5.5 מיליארד (8 סדרי גודל)
- בתרשים העליון ניתן לראות שכמעט כל הדמויות דחוסות סמוך לאפס, עם זנב ימני קיצוני של דמויות בודדות במיליארדים התפלגות א-סימטרית עם הטיה ימנית חזקה
- בתרשים התחתון אחרי טרנספורמצית $\log(1+Bounty)$ הערכים נפרסים להתפלגות מאוזנת וקרובה לנורמלית כל דמות תורמת ללמידה במידה דומה מקרי קיצון כבר לא שולטים בפונקציית השגיאה
- ה $\log$ גורם למודל ללמוד סדר גודל של איום במקום להישלט על ידי מקרי קיצון (היונקו)
- הסיבה להוספת +1 הינה לטפל בדמויות עם Bounty אפס ($\log$ של 0 אינו מוגדר)
- זו ההצדקה האמפירית להחלטה שכל האימון וההערכה כולל RMSE ו R^2 - מתבצעים בסקאלת ה $\log$

Bounty — raw scale




$\log(1 + Bounty)$





קורפוס הטקסט

Zipf's law on the One Piece corpus



- תדירות המילים בקורפוס (בכחול) יורדת כמעט בקו ישר בסקאלה לוגריתמית כפולה - בדיוק כפי שחוק Zipf מנבא (הקו המקווקו)
- זו עדות שהטקסט שחילצנו מהוויקי מתנהג כמו שפה טבעית תקינה ולא כרעש או תבנית מלאכותית
- מכאן שייצוגי TF-IDF רלוונטיים כאן: יש מבנה לשוני אמיתי שאפשר ללמוד ממנו אות חזוי



הנדסת פיצ'רים



פיצ'רים מרכזיים במודל

- פיצ'רים מקוריים
 - 50 מימדי TF-IDF+SVD מתיאור הדמות
 - שיוך ארגוני, פרי שטן וסוגו, גזע, מגדר, כינוי
- פיצ'רים שנוספו
 - 6 מדדי מרכזיות מגרף הקשרים (PageRank, ...degree)
 - ציון "איום": מילות איום פחות חיוביות, מחולק באורך הטקסט
 - דגלים מחולצים: האות "D", שלושת סוגי ה-Haki, התעוררות פרי, יונקו / שיצ'יבוקאי / הדור הגרוע
 - היסטוריית Bounty: מספר עדכונים ושינויים לאורך העלילה

טיפול במקרי קצה

- is_star_bounty - דירוגי-כוח של הממשלה (עבור מרינס) שמשקפים פעולות לטובת הממשלה ומשמעותם למעשה הפוכה. היות ומדובר בכ 30% מהדמויות המתויגות, המודל נבחן גם בהסרת אוכלוסייה
 - is_warlord - שיצ'יבוקאי עם Bounty "מוקפא" עבור כל דמות שהייתה חלק מאוכלוסייה זו נוספה +1 לכמות הקפיצות בערכי ה Bounty
 - is_yonko / is_gorosei / is_celestial - צמרת הכוח, מעט דוגמאות וערכים קיצוניים
 - is_crew - דפי צוות שסוננו מהמודלים
 - is_non_canon - דמויות המשתתפות בסרטים או בפילרים ואינן חלק מהעלילה הראשית ולכן סוננו
- בכל אחד נעשה שימוש ב Flag ייעודי שנוסף כפיצ'ר למודל



ייצוג המידע



טקסט (NLP)

- עיבוד מקדים: פירוק למילים (tokenize), הסרת stop words (מילים נפוצות חסרות משמעות) ולמטיזציה (החזרה לצורת בסיס)
- TF-IDF משקל גבוה למילים שמאפיינות דווקא את הדמות הזו ← צמצום ל 50 מימדים עם SVD
- ציון "איום": מילות איום פחות מילים חיוביות בתיאור, מחולק באורך הטקסט (מנורמל ל 1,000 מילים)

רשת (Network)

- גרף דו-צדדי דמות ↔ קבוצה, מוקרן לגרף דמויות משוקלל (מספר קבוצות משותפות = משקל הקשת)
- 1,542 צמתים, 29,568 קשתות קבוצות ענק (כמו Marines) מוגבלות - אחרת כל חייל היה מחובר לכל חייל והקשרים היו מאבדים משמעות
- מקור הקשתות: שיוך ארגוני מהאינפובוקס + קטגוריות הוויקי (כגיבוי לדמויות שהאינפובוקס שלהן חסר)
- 6 מדדי מרכזיות: degree (מספר קשרים), weighted degree (קשרים משוקללים), PageRank (חשיבות ברשת), betweenness (גישור בין קבוצות), clustering (לכידות סביבה), k-core (עומק בליבת הרשת)
- אלה 6 המאפיינים היחידים שמוזנים למודל "רשת בלבד"



מידול והערכה



- טקסט / רשת / משולב: שלושת המודלים מושווים על אותם 5 קיפולים (Stratified K-Fold), לפי רבעוני log-bounty
- מנוע: CatBoost Gradient Boosting (600 עצים, עומק 6)
עם נפילה אוטומטית ל-HistGradientBoosting אם CatBoost אינו זמין
- בקרת דליפה: SVD / TF-IDF מותאמים על train בלבד בכל fold
עמודות מזהות (שם, bounty עצמו) אינן מוזנות למודל; ערכי Bounty מפורשים מוסרים גם מהטקסט עצמו
- מדדי הערכה: R^2 ו RMSE על סקאלת ה log
ו MAE בברי אמיתיים (שגיאה ממוצעת מוחשית במטבע העולם)

3

מדדי הערכה (מעל המינימום)

5


קיפולי Cross-Validation

3

מודלים



השוואת המודלים



מודל	R ²	RMSE	MAE(מיליוני ברי)
בסיס (חציון)	-0.050	2.516	503.7
טקסט	0.367	1.953	314.1
רשת	0.131	2.289	479.4
משולב	0.424	1.863	303.5

המודל המשולב ($R^2 = 0.424$) למרות שאינו אידיאלי מהווה שיפור לעומת הטקסט בלבד (0.367) וגם לעומת הרשת בלבד (0.131) עדות שהאותות משלימים זה את זה



5
הערכה

4
מידול

3
הנדסת פיצ'רים


2
ניקוי ופענוח

1
איסוף

ניתוח רשת הדמויות



דמויות עם Bounty גבוה
יושבות בליבה הצפופה
של הרשת
דמויות ללא Bounty
נדחקות לפריפריה
מרכזיות ברשת מתואמת
עם Bounty
זה מסביר מדוע אות הרשת
תורם למודל המשולב






- 1 איסוף
- 2 ניקוי ופענוח
- 3 הנדסת פיצ'רים
- 4 מידול
- 5 הערכה




ניתוח רשת


הצוותים והארגונים

מבט משלים ברמת הקבוצה
כל צומת הוא צוות/ארגון
גודלו לפי מספר החברים
וצבעו לפי חציון ה Bounty שלהם
הצוותים החזקים (יונקו,
מרינס) בהירים ומרכזיים,
ומאשש שהשתייכות ארגונית
נושאת אות חזוי





ניתוח שגיאות



תובנה מרכזית

כל 12 הטעויות הגדולות של המודל
המשולב הן חיזוי-יתר
ללא חיזוי חסר
כולן דמויות חלשות בצוותים חזקים
(טוני טוני צ'ופר, בפו ועוד)
שהרשת "מדביקה" להן עוצמה
של השכנים שלהן
זו בדיוק שאלת המחקר בפעולה
באילו מקרים מידע הרשת עוזר
ובאילו מקרים הוא מטעה



בדיקות עמידות

בדיקת עמידות = מריצים את כל הניסוי מחדש עם שינוי מכוון אחד, כדי לוודא שהתוצאה לא תלויה בהחלטה שרירותית

כל ה-Bounty מול "מבוקש" בלבד

R^2 על כל ה-Bounty מול R^2 על מבוקשים בלבד

מודל	כולל הכל	מבוקש בלבד
בסיס	-0.050	-0.012
טקסט	0.367	0.324
רשת	0.131	0.151
משולב	0.424	0.361


המודל שומר על יחס המדדים גם בהסרת דירוגי הכוח של הממשלה
אך לא משפר את התוצאה הסופית
סימן שהמודל למד קשר אמיתי ואינו נשען על הבלבול בין השניים

שקלול קצה גבוה

R^2 ללא שקלול מול R^2 עם שקלול (יונקו $\times 4$, שיצ'יבוקאי $\times 2$)

מודל	ללא שקלול	עם שקלול
בסיס	-0.050	-0.050
טקסט	0.367	0.355
רשת	0.131	0.121
משולב	0.424	0.397

שקלול יתר לדמויות חזקות לא שיפר את ה R^2 הכללי
רוב הדמויות בעולם הן בעלות Bounty בינוני, והמדד נשלט על ידן



חיזוי לדמויות ללא Bounty רשמי

המודל המשולב אומן על 218 הדמויות בעלות Bounty והופעל על דמויות בולטות שמעולם לא הוכרז להן Bounty רשמי - הדגמה בלבד, ללא ערך אמת לבדיקה

חזוי (ברי) Bounty	דמות
2,456,000,000	Sengoku
1,719,000,000	Kuzan
1,463,000,000	Ethanbaron V. Nusjuro
1,351,000,000	Topman Warcury
1,323,000,000	Kong
1,135,000,000	Marcus Mars
1,124,000,000	Silvers Rayleigh
1,109,000,000	Jaygarcia Saturn

התחזיות סבירות ביחס לפרופיל
למשל, מפקדים בכירים לשעבר בדרג הגבוה ביותר של הממשלה מקבלים תחזית גבוהה יותר
מחברי צוות זוטרים



תרומה וחדשנות

צינור מקצה-לקצה ניתן לשחזור (Reproducible)

מ API של ויקי גולמי ועד חיזוי
כולל פענוח wikitext, בניית גרף, הנדסת מאפיינים
ובקרת דליפה קפדנית בכל fold

שילוב טקסט ורשת בדומיין נרטיבי

רוב עבודות חיזוי ה NLP מתמקדות בטקסט בלבד
כאן מודגם שאיחוד תיאור טקסטואלי עם מבנה רשת
חברתית משפר את החיזוי (R^2 עולה מ 0.367 ל-0.424)

יישום מכליל (Generalization)

המודל חוזה Bounty סביר לדמויות שמעולם לא קיבלו
אחד רשמית
הדגמה לכוח ההכללה

בדיקות עמידות (Ablation)

התוצאה נבדקה גם בהסרת דירוגי הכוח של הממשלה
וגם בשקלול קצה גבוה
והמסקנה על תרומת הרשת נשמרת



עבודה עתידית

- הפעלת ה Embeddings בריצה המרכזית: הצינור בנוי (SentenceTransformer + SVD) אך לא הופעל בהרצה הסופית - בחינת תרומתו נותרה כעבודת המשך
- העשרת הרשת: הוספת סוגי קשר (יריבות, משפחה, צוות) כמשקלים נפרדים במקום קשר אחיד
- איסוף נתונים רחב יותר: הרחבת הכיסוי מעבר ל-218 דמויות מתויגות למשל שילוב מקורות נוספים או תיוג ידני של מקרי קצה
- מודלים מתקדמים: ניסוי ב Graph Neural Networks שמשלבים ישירות מבנה רשת וטקסט, במקום מאפיינים מהונדסים
- פירוש (Interpretability): ניתוח SHAP לזיהוי אילו מילים ומדדי רשת מניעים כל חיזוי

מסקנות

- ניתן לחזות Bounty ממודל המשלב טקסט ורשת השילוב הוא המנבא הטוב ביותר ($R^2=0.424$)
- תובנה מרכזית
הפער בין מיקום ברשת לעוצמה אישית הוא מקור כל הטעויות הגדולות
- מרכזיות ברשת מתואמת עם Bounty
מסביר מדוע הרשת תורמת למודל המשולב למרות חולשתה לבדה
- המודל עמיד
התוצאות נשמרות גם בהסרת דירוגי הכוח של הממשלה מהיעד

תודה!

שאלות?





גילוי נאות על שימוש ב-AI

כלים, משימות והיקף

- Claude - הכלי המרכזי, בעיקר לקוד (שלד הקוד ודיבאגינג)
- Gemini - עזרה בניסוח הצעת הפרויקט וחוות דעת על המתודולוגיה
- Perplexity - הצלבה ובדיקה: השוואת תשובות בין הכלים ואיתור תיעוד ספרות (MediaWiki API, scikit-learn, NetworkX)
- לא נעשה שימוש ב-Kaggle בהתאם למדיניות הקורס

עריכה אנושית ואימות

- הפרוייקט התחיל כפרוייקט משותף כולל שלב ההצעה, האיסוף והארכיטקטורה המימוש, הדוח והמצגת בוצעו על ידי בלבד
- כל ההחלטות הלוגיות, המתודולוגיות והארכיטקטוניות בוצעו על ידי, כולל: יעד ה-log, שלושת המודלים, בקרת הדליפה
- אימות עצמאי: בחינת הקוד, טיובו, שילובו, הרצת הקוד, בדיקת הפלט, בדיקות שפיות על הנתונים, הצלבה מול תיעוד רשמי