

חיזוי מדד האיום (Bounty) בעולם One Piece באמצעות NLP וניתוח רשתות

נדב פיירמן שטרן

מסלול 3 פרויקט מונחה נתונים

עיבוד שפה טבעית - NLP Natural Language Processing

1. רקע על הסדרה

One Piece היא סדרת מאנגה ואנימה יפנית מצליחה מאת אייז'ירו אודה, שרצה ברציפות מאז 1997. העלילה מתרחשת בעולם ימי הבנוי בעיקר מאיים, ועוקבת אחר הפיראט הצעיר מונקי ד. לופי וצוותו במסע לאיתור האוצר האגדי "One Piece" ולהפוך למלך הפיראטים. עולם הסיפור בנוי סביב מספר גורמי כוח מרכזיים המתחרים ומתנגשים זה בזה: הממשלה העולמית (World Government) והזרוע הצבאית שלה, המרינס, השואפות לשמור על הסדר ולדכא פיראטים; ארבעת ה"יונקו" - פיראטים רבי-עוצמה השולטים כל אחד באזור נרחב בים; ה"שיצ'יבוקאי" (Warlords) - פיראטים שפעלו בעבר בחסות הממשלה תמורת חסינות; והמהפכנים (Revolutionary Army), המבקשים להפיל את הממשלה.

בעולם הזה, כל דמות שנתפסת כמאיימת - בעיקר פיראטים, אך גם ארגונים אחרים - מקבלת מהממשלה "Bounty": פרס כספי המוצב על ראשה, שגדל ככל שהיא נחשבת מסוכנת ומשפיעה יותר. ה-Bounty הוא בעצם מדד איום כמותי ורשמי בתוך עולם הסיפור, וזהו בדיוק המשתנה שבמרכז הפרויקט - כיצד ניתן לחזות אותו מתוך תיאור טקסטואלי של דמות ומתוך מיקומה ברשת הקשרים החברתיים-פוליטיים שהיא חלק ממנה.

2. מבוא ושאלת מחקר

השאלה המרכזית: האם ניתן לחזות את ה-Bounty של דמות מתוך התיאור הטקסטואלי שלה בוויקי וממיקומה ברשת הקשרים, ואיזה מקור מידע תורם יותר לדיוק? בשל טווח הערכים העצום (מעשרות ועד מיליארדים) היעד טרנספורמצית log, וזוהי בעיית רגרסיה. השווייתי שלושה משטרים: טקסט בלבד, רשת בלבד, ומשולב.

3. הנתונים

הנתונים נאספו באופן עצמאי מ One Piece Fandom Wiki דרך ה-API הציבורי, ללא Kaggle או מאגר מוכן: כ-1,734 דפים גולמיים, ומהם 218 דמויות עם Bounty ידוע המשמשות כמשתנה המטרה, ועוד מאות דמויות ללא Bounty המשמשות לבניית הגרף. אתגר ייחודי: חלק מהדמויות (מרינס, אדמירלים) נושאות דירוג כוח של הממשלה בפורמט דומה ל-Bounty - שהוא בעצם ההפך מ-Bounty של פיראט מבוקש. אלה זוהו והופרדו באמצעות דגלים ייעודיים.

4. מתודולוגיה


עיבוד מקדים: ניקוי wikitext, נרמול והסרת מילות עצירה; חילוץ ה Bounty מהטקסט באמצעות תבנית הברי כעוגן. בניית גרף ב NetworkX: כל דמות היא צומת, וקשת נוצרת בין שתי דמויות שחולקות שיוך (צוות או ארגון); מהגרף חולצו מדדי מרכזיות ודרגה. ייצוג טקסט: TF-IDF עם צמצום SVD וציון "איום" לקסיקלי. מידול: Gradient Boosting בהערכת 5-fold Cross-Validation; בקרת דליפה – ה TF-IDF או SVD מותאמים על ה train בלבד, ועמודות מזהות אינן מוזנות למודל.

5. תוצאות

הטבלה מציגה את ה R^2 (על היעד הלוגריתמי) לכל משטר מול קו הבסיס:


מודל	R^2 (log)	RMSE (log)	MAE (מיליוני ברי)
קו בסיס (חציון)	-0.050	2.516	503.7
טקסט בלבד	0.367	1.953	314.1
רשת בלבד	0.131	2.289	479.4
משולב	0.424	1.863	303.5

המודל המשולב נותן את התוצאה הטובה ביותר ומנצח את הטקסט לבדו - עדות לכך שהטקסט והרשת נושאים אות משלים. הטקסט לבדו חזק בהרבה מהרשת לבדה, וקו הבסיס שלילי כצפוי. RMSE ו MAE (במיליוני ברי) מופיעים בטבלה לצד ה R^2 .




6. ניתוח הרשת

גרף הקשרים מראה שהדמויות בעלות ה Bounty הגבוה יושבות בליבה הצפופה והמקושרת, בעוד דמויות ללא Bounty נדחפות לפריפריה. כלומר מרכזיות ברשת מתואמת עם Bounty - וזה מסביר מדוע אות הרשת תורם למודל המשולב.



7. ניתוח שגיאות

בחינת הטעויות הגדולות של המודל המשולב חושפת תבנית ברורה: כולן חיזוי יתר, וכולן דמויות חלשות שנמצאות בצוותים חזקים (למשל צ'ופר ובפו). המודל מנפח דמויות שקרובות ברשת לדמויות חזקות - פער בין המיקום ברשת לבין העוצמה האישית. זו בדיוק שאלת המחקר בפעולה: מתי מידע הרשת עוזר, ומתי הוא מטעה. בדיקות עמידות חיזקו את התמונה: שקלול-יתר של הדמויות החזקות באימון דווקא הוריד את ה R^2 הכולל (רוב הדמויות בינוניות ושולטות במדד), והרצה על Bounty "מבוקש" בלבד (ללא דירוגי הממשלה) שמרה על אותו דירוג משטרים.



8. מסקנות ומגבלות

ניתן לחזות Bounty מטקסט ומרשת, והשילוב הוא המנבא הטוב ביותר. מגבלות: מדגם מתויג קטן (218 דמויות), הטיה לכיוון דמויות פופולריות המתועדות בפירוט רב יותר, ודירוגי הכוח של הממשלה שאינם Bounty אמיתי ועלולים להטות את היעד. כיישום, המודל המשולב הופעל גם על דמויות בולטות ללא Bounty רשמי (כגון ריילי וסנגוקו) להפקת אומדן חזוי. שיפור עתידי: הפעלת צינור האמבדינגים (MiniLM) שממומש בקוד אך לא הופעל בריצה הסופית, ואיסוף נתונים נוסף.

9. גילוי נאות על שימוש ב AI

השתמשתי בכלי AI ככלי עזר בלבד. Claude - הכלי המרכזי, בעיקר לקוד (שלד ודיבאגינג); Gemini - ניסוח ההצעה וחווה דעת על המתודולוגיה; Perplexity - הצלבה ואיתור תיעוד ספריות. כל ההחלטות המתודולוגיות בוצעו על ידי (יעד ה-log, שלושת המודלים, בקרת הדליפה). אימות עצמאי: בחינת הקוד וטיובו, הרצה ובדיקת פלט, בדיקות שפיות והצלבה מול תיעוד רשמי; אני יכול להסביר כל שורה. לא נעשה שימוש ב-Kaggle או בטרנספורמרים ללא ניתוח.

10. רפלקציה אישית

למה בחרתי בנושא. בחרתי ב One Piece כי זו פשוט סדרה שאני עוקב אחריה שנים: היא רצה ברציפות מאז 1997, עוד לפני שנולדתי. רציתי פרויקט על משהו שאני באמת מכיר ואוהב, כי ידעתי

שככה תהיה לי סבלנות לרדת לפרטים הקטנים של הנתונים - וזה בדיוק מה שקרה. ה Bounty שבמרכז הפרויקט הוא מדד איום כמותי שהממשלה שבעולם הסיפור מציבה על ראשה של כל דמות מאיימת - בדיוק סוג המשתנה שאפשר לנסות ללמוד מהטקסט ומרשת הקשרים. מה מימשי אישית. אספתי את הנתונים בעצמי מ Fandom Wiki דרך ה API, ניקיתי את הטקסט, חילצתי את ה Bounty, בניתי גרף קשרים בין הדמויות, ואימנתי שלושה מודלים - טקסט בלבד, רשת בלבד, ומשולב - מול קו בסיס, עם $RMSE$, R^2 ו MAE , ניתוח שגיאות ושש ויזואליזציות. יומן כישלונות: שלושה דברים שנכשלו וכיצד תוקנו. (1) בהתחלה התייחסתי לכל ערך מספרי בתבנית כ Bounty אחיד. גיליתי שחלק מהדמויות נושאות דירוג-כוח של הממשלה בפורמט דומה - שהוא בעצם ההפך מ Bounty של פיראט מבוקש - וזה עיוות את היעד; תיקנתי בזיהוי דירוגי הכוכבים והפרדתם באמצעות דגלים ייעודיים. (2) חילוץ היסטוריית ה Bounty נשבר על תגי HTML, ולקח לי זמן למצוא למה: ערכים ישנים בוויקי עטופים בתג $<s>$ (קו חוצה), וה regex נעצר בהם - כך שהערך המזערי יצא זהה לערך המרבי וההיסטוריה אבדה; תוקן בהסרת תגי ה HTML לפני החילוץ. (3) גרף של כ 1,000 דמויות יצא בהתחלה "כדור צמר" בלתי קריא; ניסיתי כמה ספי גיזום עד שהגעתי לשילוב של k-core עם החזרת כל בעלי ה Bounty, וציור בשכבות (דמויות ללא Bounty דהויות ברקע). אתגר נוסף: בקרת דליפה. דאגתי שה TF-IDF וה SVD יותאמו על ה train בלבד בכל fold, שמספרי ה Bounty יימחקו מהטקסט עצמו לפני המידול, ושעמודות מזהות לא יגיעו למודל. מה למדתי ומה הפתיע אותי. הממצא המרכזי היה גם הכי מספק: טקסט ורשת נושאים אות משלים - השילוב מנצח כל אחד לבד. הכי הפתיע אותי ששקלול הדמויות החזקות דווקא הוריד את ה R^2 הכולל - רוב הדמויות בעולם בינוניות, והמדד נשלט על ידן. תובנת השגיאות: המודל מנפח דמויות חלשות בצוותים חזקים (צ'ופר, בפו) - פער בין "עם מי אתה" לבין כמה חזק אתה באמת. בעצם זו שאלת המחקר בקטן: הרשת מוסיפה מידע אמיתי, אבל גם רעש שיטתי שלמדתי לזהות. מה הייתי משפר בדיעבד. הפעלת האמבדינגים בריצה הראשית - הצינור כבר בנוי, כך שזה שינוי של דגל אחד; איסוף נתונים מתויגים נוספים כדי לחזק את הקצה הגבוה של ההתפלגות; וטיפול עשיר יותר בדירוגי הממשלה כמשימת חיזוי נפרדת במקום סינון בלבד. יומן עבודה קצר. אפריל: גיבוש שאלת המחקר והגשת ההצעה (8.4), קבלת משוב ועדכון ההצעה. מאי: הגשת ההצעה המתוקנת (3.5), כתיבת איסוף הנתונים מול ה-API והרצת האיסוף המלא, ניקוי wikitext וחילוץ ה-Bounty כולל תיקון באג דירוגי הכוכבים ותגי ה- $<s>$. יוני: הנדסת פיצ'רים, בניית הגרף ומדדי הרשת, הרצת שלושת המשטרים ב-Cross-Validation, ניתוח שגיאות, בדיקות עמידות וויזואליזציות, פיצול הצוות (27.6) וקבלת אישור להגשה עצמאית. יולי: בניית המצגת, כתיבת הדוח וקבצי ה-MD, סידור המחברת והכנת ההגשה הסופית. עבודה עצמאית. הפרויקט התחיל כעבודת זוג. בעקבות חילוקי דעות מקצועיים נפרדנו, וקיבלתי אישור מהמרצה להמשיך ולהגיש לבד. מאותה נקודה כל המוגש כאן נעשה על ידי. הפירוד גם לימד אותי לתעד כל שלב ולוודא שכל חלק בצינור עומד בפני עצמו, כי כבר לא היה שותף לבדוק מולו.